

トーラス型自己組織化特徴マップを用いた やすりがけ技能学習時の動作傾向分類

○寺西 大, 松本 慎平, 竹野 英敏 (広島工業大学)

Peculiarity Classification of Flat Finishing Motion Training by Using Torus Type Self Organizing Maps

○Masaru TERANISHI, Shinpei MATSUMOTO, and Hidetoshi TAKENO

(Hiroshima Institute of Technology)

Abstract : The paper proposes an unsupervised classification method for peculiarities of flat finishing motion with an iron file, measured by a 3D stylus. The classified personal peculiarities are used to correct learner's finishing motions effectively for skill training. In the case of such skill training, the number of classes of peculiarity is unknown. A torus type Self-Organizing Maps is effectively used to classify and visualize such unknown number of classes of peculiarity patterns. Experimental results of the classification with measured data of an expert and sixteen learners show effectiveness of the proposed method.

1. はじめに

中学校技術教育の現場では、ものづくり教育に重要とされる各種加工技術の技能伝承のための教材開発が進められている。これらの技能を習得するには、(1) 熟練者の動作をまねつつ、(2) 学習者が自らの「クセ」に気づき、意識してそれを修正することが重要と考えられる。

しかし従来の教材の大半はテキストや静止画像、動画像で構成されている。これらの教材からは熟練者の動作の概略は読み取ることはできても、工具の時間的な細かい動きや姿勢の動きを読み取れず、まねるには困難がともなう。また工具の姿勢およびその時間的な動きは目視で詳細をまねるのは難しい。さらに、上記の教材からは学習者が熟練者の動作と自分のそれとの差からクセを意識することも困難と思われる。

本研究では、ものづくり技能伝承の必要性が求められている切削・研磨技能の一つである「鉄工やすりによる平面仕上げ加工」を習得するための新しい支援システムを開発している [1, 2, 3, 4, 5, 6]。提案システムでは 3 次元スタイラス装置により、学習者のやすりの動作を計測してその「クセ」を分類検出する。検出したクセおよび学習者と熟練者の動作との差分に基づいて、画面または力覚フィードバックにて修正方法を提示する。本研究では、本システムのパターン分類機能として 3 次元スタイラス/力覚フィードバック装置を用いて計測したやすり操作データに自己組織化特徴マップ (Self-Organizing Maps, 以下では SOM)[7] を適用して学習者の「クセ」、すなわち個人パターンの自動分類を試みる。「クセ」の可視化を意識した特徴量として、やすりがけ動作の主方向の速度変化に基づいた特徴量の抽出とその分類を試みる。さらに、SOM の性能低下の一因となるマップ端での位相歪みを改善し、クセ

分布・分類の可視化を容易にする目的で、マップ端のないトーラス型 SOM[8] を導入する。「クセ」の自動グループ化のために、自動クラスタリング手法 [9] を導入する。

2. 平面仕上げ技能計測システム

Fig.1 に、平面仕上げ技能計測システムの外観を示す。加工対象である角柱形状のワークの上面を、鉄工やすり (平やすり) で平面仕上げを行うことを想定し、このときのやすりの 4D データ (3 次元+時間変化) を 3 次元スタイラスで計測する。本システムでは、SensAbleTechnologies 社製 3 次元触覚/力覚インタフェースデバイス PHANTOM Omni のエンコーダスタイラス部に鉄工やすりの柄部分を取り付ける。やすりの本体は力覚フィードバック教示においてデバイスの負荷を軽減するため、実物ではなくアクリル素材で呼び寸法 200mm の平やすりを模した模擬やすりを取り付けてある。模擬やすりにて木製ダミーワーク ($W25 \times D25 \times H80$ mm) の上面を平面に仕上げる動作を行い、そのときのやすりの 3 次元空間での動きを計測する。やすりと 3 次元の各軸との対応関係は Fig.2 となる。計測されるデータはやすりの位置、すなわちエンコーダの (X, Y, Z) 位置、およびやすりの姿勢を表わすエンコーダのヨー、ピッチ、およびロー角度 (T_x, T_y, T_z) の 6 つの時系列となる。本システムで計測された熟練工のやすりの変位を Fig.3 に、学習者の変位を Fig.4 にそれぞれ示す。これらの図では、約 20 秒間に 4 回のやすりの往復運動がなされている。やすりの動きは主に X 方向の往復運動となり、X が減少する動きがやすりを押す動作、その反対が引く動作となる。このやすりは押す動作で切削となるので、以下では押し動作を解析対象とする。

また本システムでは、あらかじめ記録したエンコーダの動きを再生して動かすことができる。本研究では、学習者がやすりを操作する際には、記録された熟練工の動きが再生されて提示される。これに沿ってやすりを動かすことで、熟練工の動きをなぞって「まねる」方法で学習を行う。



Fig. 1: 平面仕上げ技能習得支援システム計測部の外観




Fig. 2: 計測時の座標軸設定

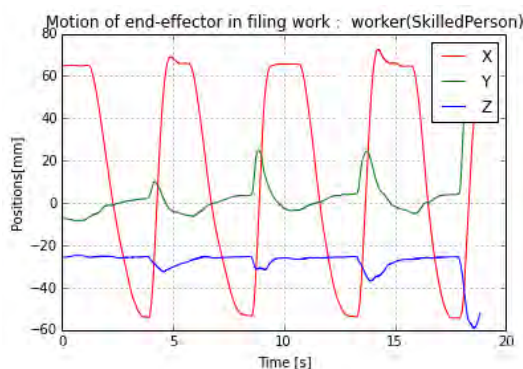


Fig. 3: 工具の変位 (熟練者)

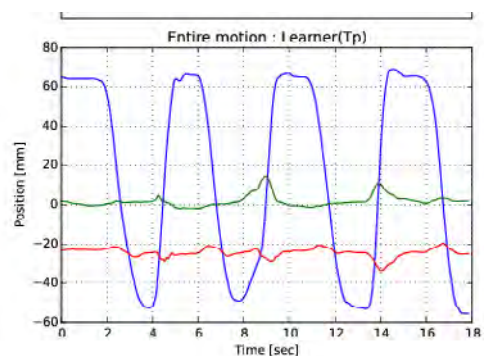


Fig. 4: 工具の変位 (学習者)

3. やすり速度変化に基づくクセ特徴量抽出

3.1 データ前処理：やすり押し動作の切り出しとリサンプリング

本システムで計測したやすり動作データを SOM に入力する際に、パターンの次元数となる押し動作の標本時刻点を同一にするために、すべての押し動作について、下記のリサンプリング処理を施す。

まず、X 軸に関して押し動作の開始位置 X_{begin} と終了位置 X_{end} を定め、この区間をやすりが通過する期間の押し動作の時系列を切り出す。切り出したそれぞれの押し動作はそのサンプリング点数が異なるので、これを $n = 100$ 点に統一するリサンプリング処理を行う。リサンプリング後の熟練者の 4 回の押し動作、ならびに学習者 1 名の 4 回の押し動作をそれぞれ Fig.5 に示す。

3.2 個人特徴量の算出：速度変化差分

上記のように求めた変位パターンにはクセ情報が間接に含まれてはいるものの、学習者がこれを見るだけでは自分の「クセ」の認識や理解が困難である。また、学習者に対して修正のための具体的な指示を与えにくい。そこで本研究では、各時刻におけるやすりの速度を求めて速度の時間変化を提示することで、やすりの速度調整の方法という観点から学習者にわかりやすい特徴量を計算する。

本研究では、やすりの各時刻における速度を近傍 2 時刻での中央差分にて近似的に求め、この時系列を速度変化と定義する。熟練工および学習者のやすり速度変化を Fig.6 に示す。Fig.6 から学習者の動作再現性が低いことは明白であるが、熟練工においてすら速度変化としての動作再現性に揺らぎがあることがわかる。そこで熟練工動作の平均を熟練者の理想的な速度変化として、これを学習者にとっての「お手本」とする。さらに、学習者の修正すべき「クセ」は、学習者の速度変化と理想速度変化との差分を求め

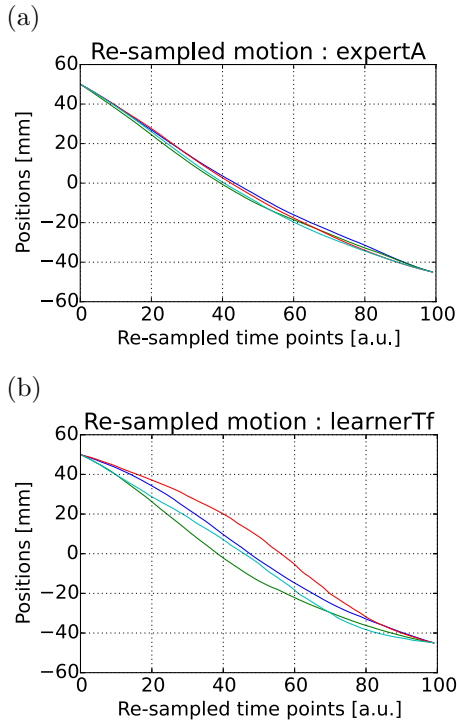


Fig. 5: リサンプリング後のやすり動作 (X 位置):(a) 熟練者, (b) 学習者

ることで、視覚的に理解しやすくなる。以下ではこの差分を「速度変化差分」と定義し、「クセ」分類の特徴量として SOM への入力とする。Fig.7 に学習者の速度変化差分を示す。もしも学習者の速度変化がお手本を十分にまねていれば、速度変化差分はほぼ 0 の無変動を示し、修正が不要であることが直ちに視認できる。

Fig.7 を見ると、学習者やすりがけの各回で理想速度変化よりも動作が速すぎる時間帯と遅すぎる時間帯があり、速度ムラがある。また速度変化差分自体に再現性が乏しく、動作が一定していないことがわかる。学習者に速度変化差分を提示しながら、これらの箇所について「この部分はもっと速く動かすほうが良い」などの修正指示を与えやすくなる。

4. トーラス型 SOM による押し動作の個人特徴分類と可視化

上記で求めた速度変化差分について、トーラス型 SOM を用いて個人パターンの自動分類を行う。やすり動作の分類についての技術的な問題として、つぎの 3 つが主要なものとして考えられる。(1) 個人パターンがやすりの動きデータのどのような箇所に特徴的に出現するのか明示的でないこと、(2) クラス数、すなわち個人パターン数があるかじめ不明であること、(3) 同一個人であっても加工の各回において、個人内のばらつきも存在すること。

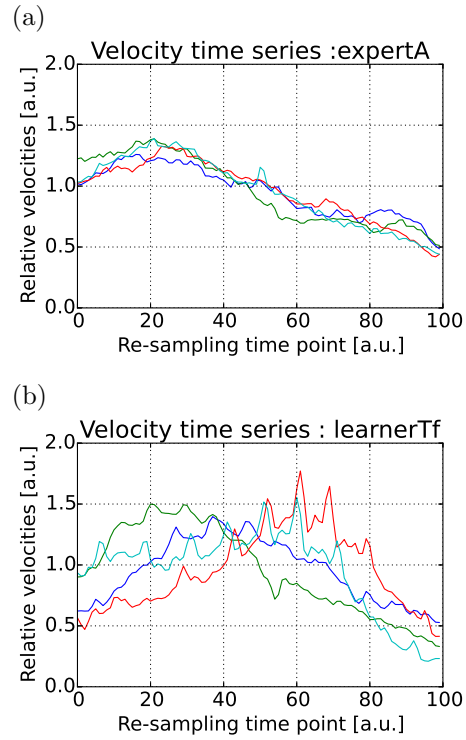


Fig. 6: やすり速度変化 (X 位置):(a) 熟練者, (b) 学習者




Fig. 7: 速度変化差分 (理想速度変化からのずれ) : 学習者

本研究では、このような主問題にうまく対応できるパターン分類器としてトーラス型 SOM が適していると考えられる。また、トーラス型 SOM によるやすり動作パターンの分布などを理解しやすくするために、田中らが提案したクラスタマップによる自動クラスタ分割 [9] を用いる。以下ではまず、トーラス型 SOM のベースとなる通常型 SOM とそれを用いたパターン分類方法を説明する。

4.1 SOM の構成

SOM は上記のようにクラス数が不明なパターンの自動分類に適したニューラルネットワークである。Fig.8 に、本研究で用いる SOM の構成を示す。SOM は入力層とマップ層の 2 層からなるニューラルネットワークである。入力層は入力パターン $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ の次元 n と同数

のユニットを持つ。各ユニット u_k^{in} には入力パターンのそれぞれの要素 x_k が入力される。マップ層は 2 次元状に配置されたマップユニットで構成される。それぞれのマップユニット $u_{(i,j)}^{map}$ は入力層のすべてのユニットと重み $m_{(i,j)}$ で全結合されている。ここで (i,j) は 2 次元の格子点を表す。この重み $m_{(i,j)}$ をコードブックベクトルと呼び、入力ベクトルについて、次式の条件を満たして最も近いコードブックベクトル m_c を持つマップユニット u_c^{map} が「発火」することで、入力パターンの分類を行う。

$$\|x - m_c\| = \min_{(i,j)} \{\|x - m_{(i,j)}\|\} \quad (1)$$

SOM は多次元パターン入力をその類似性にもとづいて、マップユニットの発火として分類する。またマップユニットは 2 次元的に配置されており、類似したパターンを持つマップユニットは、マップ上で近い場所に位置する。このため、多次元空間でのパターンの類似性を 2 次元マップに射影して容易に可視化できる。また SOM におけるパターン分類の形成、すなわち類似性をもつパターンをマップ上のどのユニット位置に配置するかは、次に述べる「自己組織化」プロセスにより行われる。

自己組織化は、(1) 入力パターンを提示し、(2) これに対して式 (1) を用いて「発火」ユニットを求めて、(3) 「発火」ユニット周辺のコードブックベクトルを修正するというプロセスを、すべての入力パターンに対して繰返し行うことでなされる。上記 (3) において、コードブックベクトルは、基本的に現状のコードブックベクトルを入力パターンの方向に修正される。コードブックベクトルの修正量は、該当ユニットと発火ユニットの距離に基づく「近傍関数」 h_{ci} により重みづけられ、次式のように決められる。

$$m_{(i,j)}(t+1) = m_{(i,j)}(t) + h_{c(i,j)}(t) \{x(t) - m_{(i,j)}(t)\} \quad (2)$$

ここで t は現在の修正回数を、 $t+1$ は次回の修正回数を表す。近傍関数 h_{ci} はコードブックベクトルの修正を発火ユニットの周辺に局所的に制限するための関数である。本研究では、発火ユニットからのマップ上での距離に応じてガウス分布状に修正量を減衰させる Gaussian 型を用いる。ガウス分布の広がりには修正回数 t とともに減少させる。

4.2 トーラス型 SOM

通常の自己組織化では、マップ端に位置するコードブックベクトルに入力パターンの多くが集中することにより、マップ歪みが生じることがある。この歪みにより、マップ端のコードブックが入力パターンのクラスを適切に代表しなくなり、分類性能が低下する。この問題は、マップ端コードブックの外側近傍にコードブックが存在しないため、マップ端コードブックが特徴空間で適正な方向に修正され




Fig. 8: SOM の構造

ないことにより引き起こされる。この問題への対策として、マップの両端をそれぞれお互いの近傍とする、トーラス型 SOM や球面型 SOM の適用が挙げられる [7, 8]。とくにトーラス型 SOM は、特徴マップのマップ端に各々の反対側のマップ端と近接関係を持たせるだけでよいので、従来型の SOM に簡単な改造を加えて実装できる。

そこで本研究では、トーラス型 SOM を用いて速度変化差分の分類を行う。トーラス型 SOM を用いることでマップ端が無くなるため、マップ歪み問題は低減できると考えられる。さらに、特徴マップを 2 次元可視化するには、任意のコードブックベクトルを中心にすることができる。このため、本研究で扱う「クセ」の分類・可視化においては、熟練工の模範動作に対応するコードブックベクトルを中心にすることができるため、可視化の点においても従来型 SOM より使い勝手がよい。

4.3 クラスタマップによる自動クラスタ分割

トーラス型 SOM により、やすり動作パターンはその類似度に基づいて、マップ上に適切に分類される。しかし、それらをクラスタに分割するのはマップ距離の目視による手作業となり、クラスタ数が不明のまま進めることとなる。また、マップ端が存在しないというトーラス型 SOM の特性のため、特徴マップを 2 次元に展開した場合、どこからどこまでが 1 つのクラスタかがわかりづらい。

田中らは自己組織化後に得られる 1 つのコードブックベクトルについて、それに隣接するコードブックベクトルの平均距離を求めることにより、そのコードブックベクトル付近の凝集度合いを表す指標とした。さらにこれに基づいた自動クラスタリング手法を提案している [9]。本報告では分類結果の可視化、およびクラスタリング手法に上記の自

動クラスタ分割を用いる。自動クラスタ分割では、ある程度ラフな形でコードブックベクトル密度の極大ごとにクラスタを用意することが必要と考え、それを検出するために、クラスタマップと呼ぶ次式で定義される2次元関数を作成する。

$$d(i, j) = \frac{1}{|D(i, j)|} \sum_{(\mu, \nu) \in D(i, j)} (\mathbf{m}_{(i, j)} - \mathbf{m}_{(i-\mu, j-\nu)}) \quad (3)$$

ここで $D(i, j)$ は (i, j) の1次近傍であり、正方格子点だと4点、六方格子だと6点ある。この関数 $d(i, j)$ はデータ密度の逆関数のような性質を持つので、この値の小さいコードブックベクトルを起点にクラスタ番号を割り振ることで、自動クラスタリングが行える [9]。

5. 個人特徴分類実験

提案手法の有効性を確認するため、やすり押し動作の個人特徴分類の基礎実験を行った。熟練者1名については4回の押し動作、学習者16名についてはそれぞれ3から4回の押し動作の総計66データを分類対象データとした。これらを $X_{begin} = 50(mm)$, $X_{end} = -45(mm)$ の区間で切り出し、 $n = 100$ 点でリサンプリングしたデータを生成し、それぞれ速度変化差分を求めた。トーラス型 SOM は入力層100ユニット、マップ層には $7 \times 7 = 49$ ユニットの Hexa 型に配置した構成を使用した。自己組織化回数10000、学習係数 α 初期値0.01、初期近傍半径7のパラメータ設定で自己組織化を行った。また、同一パラメータで従来型の SOM の自己組織化を行い、性能を比較した。

トーラス型 SOM、従来型 SOM での熟練者と学習者のデータに対する発火ユニットの位置を Fig.9 に示す。トーラス型 SOM の特徴マップは、クラス分布の可視化を良くするために、熟練者パターンに対応するユニットが中心になるように表示した。

熟練者のパターンに対応するユニットは、トーラス SOM では近接した3つのユニットに分布した。一方、従来型 SOM では熟練者パターンがやや離れたユニットに分散している。学習者のパターンの中には、熟練者と同じユニットに発火しているものもあり、熟練者の動きをなぞる学習法の一定の効果が確認できる。

手本の動きとは異なる個人のクセを表わすパターンは、各々複数の類似性が高いパターンが同じユニットに発火している。凝集度に基づく自動クラスタリングを適用した結果、従来型 SOM では5クラスタ、トーラス型 SOM では4クラスタに分割された。従来型 SOM では、熟練者パターンが2クラスタにまたがっている。また、各クラスタの境界付近では、速度変化差分の形状から明白に同一クラスタと考えられるデータが、異なる2クラスタに分類されてい

る。これに対してトーラス型 SOM では、熟練者パターンは1クラスタに集約されており、クラスタ境界では速度変化差分も異なる形状となっている。また表示におけるマップ端にまたがるクラスタリングも的確に行えている。手本を含むクラスタ1には多くの学習者データが含まれているが、速度変化差分の形状を見ると明らかに手本とはかけ離れた動きのパターンも見られる。

特徴マップの中で、複数のパターンが集中したユニットそれぞれについて、そのユニットのコードブックベクトルで分類される元データを Fig.10 に示した。この結果においても、従来型 SOM では速度変化差分の形状の異なるデータが1ユニットにまとめられているが、トーラス SOM ではほぼ同じ形状の速度変化差分しかまとめられておらず、より適正な形で分類がなされている。

マップ歪みの改善については、従来型 SOM のマップ端を拡張する [6] ことでも同程度の効果が認められたが、拡張後の再自己組織化により、実質2倍の計算量を必要としたり、拡張すべきマップ端の選択などの調整項目が必要となる。提案手法はこの手法に比べて、2分の1の計算量で同程度の性能が得られているので高速である。また任意のコードブックをマップ中心に表示できる点でもトーラス SOM は使い勝手が良い。

自己組織化の性能指標の1つである平均量子化誤差 [7] は、トーラス SOM では0.888であり、従来型 SOM の0.922よりも低減されている。

自動分割された4つの各クラスタにおけるコードブックベクトルをまとめると、Fig.11のようになっている。クラスタ1は熟練者パターンを含むクラスタである。技能習得指導においては、このクラスタに見られる程度の学習者の速度変動は許容でき、お手本どおりと見なせるとも解釈できる。「クセ」を表わすクラスタ2は、お手本とは顕著に異なる速度変化を示している。これに対してクラスタ3と4については、同様の傾向となった。「クセ」のパターンであるクラスタ2,3,4に見られる共通特徴として、やすりがけ開始時の速度が遅くなるということが挙げられる。

6. おわりに

本研究では、平面仕上げ技能習得支援システム開発のパターン分類機能として、3次元スタイラスで計測したやすり操作データに自己組織化特徴マップを適用し、学習者の「クセ」の自動分類を試みた。トーラス型 SOM を用いることで速度変化差分形状を分類する能力、量子化誤差の両者において、分類性能を従来型 SOM に比べて改善できることが示された。また自動クラスタリング手法を導入することで、「クセ」の可視化・把握が容易になることも示された。今後の課題として、マップサイズおよび組織化パラメー

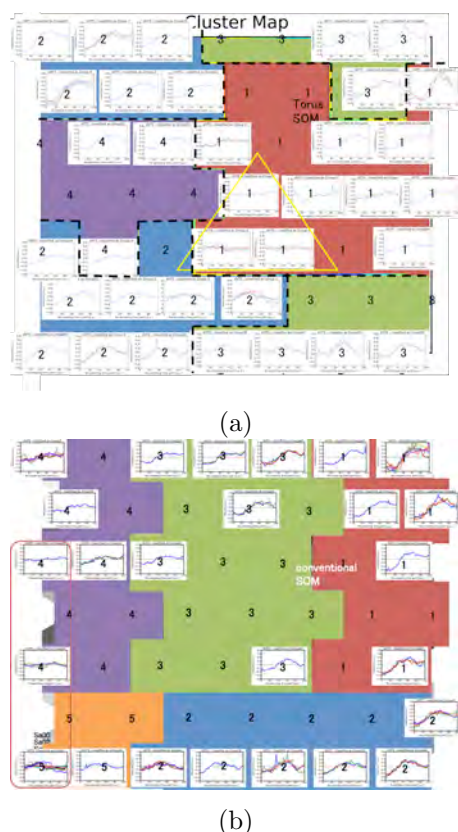


Fig. 9: 自己組織化後の特徴マップ：(a) トーラス SOM, (b) 従来型 SOM. 実線で囲まれた部分は熟練者データ, 色分けされた区画は各クラスターを表わす.




Fig. 10: 1つのコードブックベクトルへの分類性能の比較：上段は従来型 SOM, 下段はトーラス型 SOM.

タの調整によるさらなる分類の最適化, 自動クラスタリング結果と動作データの「クセ」グループ関係の妥当性の検討, マップで示された位相分布情報の活用法, x-means 法などの他の自動クラスタリング手法との比較, さらに Y および Z 位置, ならびに工具姿勢までを統合した特徴分類方法の検討が挙げられる.

7. 謝辞

本研究は, 独立行政法人日本学術振興会平成 29 年度科学研究費助成事業 (基盤研究 (C)(一般) 課題番号 17K04827) の助成を受けて実施した成果の一部である. ここに記して謝意を表します.

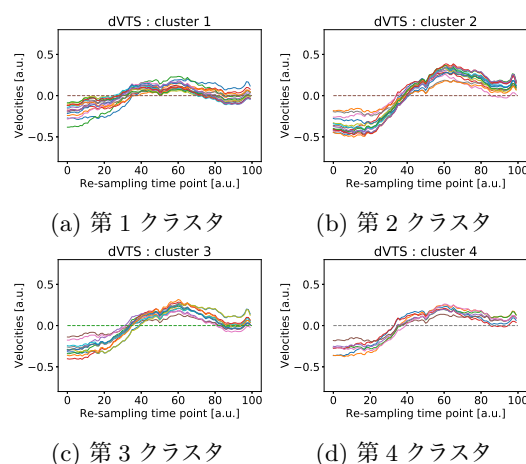


Fig. 11: トーラス型 SOM:各クラスターにおけるコードブックベクトル

参考文献

- [1] 竹野英敏, 安藤明伸, “力覚フィードバック装置を用いた平面仕上げ技能習得支援システムの開発”, 日本産業技術教育学会第 56 回全国大会講演要旨集, 2Fa5, 2013.
- [2] 寺西大, 松本慎平, 竹野英敏, “平面仕上げ技能習得のための自己組織化特徴マップによる動作の個人特徴分類”, 平成 26 年電気学会電子・情報・システム部門大会講演論文集, OS11-8, pp. 1144-1147, 2014.
- [3] 寺西大, 松本慎平, 竹野英敏, “平面仕上げ技能習得のためのやすりかけ動作個人特徴計測”, 第 15 回計測自動制御学会システムインテグレーション部門講演会論文集, 3D2-2, pp.2018-2021, 2014.
- [4] S. Matsumoto, M. Teranishi, H. Takeno, “A Training Support System of Brush Coating Skill with Haptic Device for Technical Education at Primary and Secondary Schools”, *Proc. of The Twentieth International Symposium on Artificial Life and Robotics 2015 (AROB 20th 2015)*, pp. 198-203, 2015.
- [5] 寺西大, 藤本, 松本慎平, 竹野英敏, “技能習得のための自己組織化特徴マップを用いた鉄工やすり平面仕上げ動作の個人特徴分類：速度変化にもとづく特徴量の検討”, 平成 27 年電気学会電子・情報・システム部門大会講演論文集, OS4-10, pp. 686-691, 2015.
- [6] 寺西大, 藤本, 松本慎平, 竹野英敏, “自己組織化特徴マップによる鉄工やすり平面仕上げ動作学習の学習者特徴分類”, 平成 28 年電気学会電子・情報・システム部門大会論文集, TC6-13, pp.179-184, 2016.
- [7] T. Kohonen, “Self-Organizing Maps”, *Springer*, 2001.
- [8] Ito, M., Miyoshi, T. and Masuyama, H., “The characteristics of the torus self-organizing map”, *6th Intl. Conf. on Soft Computing (IIZUKA2000)*, pp.239-244, 2000.
- [9] 田中雅博, 古河靖之, 谷野哲三, “自己組織化マップを利用したクラスタリング”, 電子情報通信学会論文誌 D-II, Vol.J79-D-II No.2, pp.301-304, 1996.